



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

**ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ
ΥΛΙΚΩΝ**

**«Χρήση της βαθιάς μάθησης για ανίχνευση και
ταξινόμηση αρρυθμίας μέσω ηλεκτροκαρδιογραφημάτων
(ΗΚΓ)»**

Εξαμηνιαία Εργασία

στο μάθημα «Μετρήσεις και Έλεγχοι στη Βιοϊατρική Τεχνολογία»

των φοιτητών

**Ηλιόπουλος Ανδρέας , Α.Μ.: 03120815
Βασιλείου Τερέζα Άννα , Α.Μ.: 03120403
Αυγερινός Πέτρος, Α.Μ.:03115074
Πάστρας Λουκάς, Α.Μ.:03115159**

Διδάσκοντες: Γ. Ματσόπουλος, Κ. Πολιτόπουλος, Ε. Αλεξανδράτου, Ο. Πετροπούλου

Αθήνα, Νοέμβριος 2023

Περίληψη

Η παρούσα εργασία διερευνά την εφαρμογή τεχνικών βαθιάς μάθησης, για την ανίχνευση και ταξινόμηση καρδιακών αρρυθμιών μέσω της ανάλυσης ηλεκτροκαρδιογραφημάτων (ΗΚΓ). Αξιοποιώντας τις δυνατότητες των CNN, η εργασία εμβαθύνει στο περίπλοκο έργο της διάκρισης των μη φυσιολογικών καρδιακών ρυθμών με χρήση των ΗΚΓ. Προβήκαμε σε πειράματα τα οποία περιλαμβάνουν μια συστηματική αξιολόγηση διαφόρων υπερπαραμέτρων ενός μονοδιάστατου συνελεκτικού δικτύου (1D CNN). Η παραμετροποίηση έγινε στον αριθμό των φίλτρων του δικτύου, στο μέγεθος των φίλτρων αυτών, στον αριθμό των dense layers του FNN (Feed Forward Neural Network) στα οποία κατευθύνεται η έξοδος του συνελεκτικού δικτύου CNN, στο ποσοστό dropout rate προς αποφυγή της αδυναμίας του δικτύου να γενικεύει, και στα μεγέθη των batch sizes, για τη βελτιστοποίηση της απόδοσης του μοντέλου. Χρησιμοποιήθηκαν για την αξιολόγηση του δικτύου διάφορες μετρικές οι οποίες είναι συνδεδεμένες με την αξιολόγηση δικτύων μηχανικής μάθησης και βαθιάς μάθησης όπως accuracy, recall και sensitivity όπου επιτεύχθηκαν σημαντικά αποτελέσματα. Τα αποτελέσματα αυτά τονίζουν τη σημασία για περαιτέρω ανάπτυξη συστημάτων τεχνητής νοημοσύνης και βαθιάς μάθησης για βελτίωση των μετρικών. Η μελέτη συμβάλλει στο εξελισσόμενο τοπίο των εφαρμογών τεχνητής νοημοσύνης στην ιατρική διάγνωση, ρίχνοντας φως στις δυνατότητες της βαθιάς μάθησης για τη βελτίωση της ακρίβειας της ανίχνευσης αρρυθμιών μέσω της ανάλυσης του ΗΚΓ.

Λέξεις Κλειδιά

ηλεκτροκαρδιογράφημα (ECG), αρρυθμία, βαθιά μάθηση (DL),συνελκτικό νευρωνικό δίκτυο (CNN).


Πίνακας Περιεχομένων

«Χρήση της βαθιάς μάθησης για ανίχνευση και ταξινόμηση αρρυθμίας μέσω ηλεκτροκαρδιογραφημάτων (ΗΚΓ)»	1
1 Εισαγωγή.....	5
1.1 Ρόλος Τεχνητής Νοημοσύνης στην Υγεία	6
1.2 Καρδιά	7
1.3 Αρρυθμία	8
1.3.1 Ηλεκτροκαρδιογράφημα – ECG (ΗΚΓ)	10
1.4 Σχετική Έρευνα	12
2 Υλικό και Μέθοδοι.....	14
2.1 Νευρωνικά Δίκτυα.....	14
2.1.1 Τεχνητά Νευρωνικά Δίκτυα	14
2.1.2 Συνελκτικά Νευρωνικά Δίκτυα (CNNs):.....	15
2.1.3 BiLSTM	20
2.2 Σύνολο Δεδομένων προς Ανάλυση	21
2.3 Πειραματική Διαδικασία	21
2.3.1 Υλοποίηση Μοντέλου.....	22
3 Αποτελέσματα.....	25
3.1 Αξιολόγηση Συστήματος για διάφορες τιμές Υπερπαραμέτρων.....	25
4 Συμπεράσματα - Επίλογος.....	29
4.1 Συμπεράσματα Εργασίας.....	29
4.2 Μελλοντικές Κατευθύνσεις Έρευνας	30
5 Βιβλιογραφία	31

1

Εισαγωγή

Η ταχεία πρόοδος της τεχνολογίας βαθιάς μάθησης έχει ανοίξει νέους ορίζοντες στον τομέα της ιατρικής, ιδίως στη διάγνωση και τη θεραπεία των καρδιακών αρρυθμιών[13][14]. Στην παρούσα μελέτη, διερευνούμε τη χρήση της βαθιάς μάθησης για την ανίχνευση και ταξινόμηση αρρυθμιών μέσω ηλεκτροκαρδιογραφημάτων (ΗΚΓ). Τα ΗΚΓ παρέχουν κρίσιμες πληροφορίες σχετικά με τις καρδιαγγειακές παθήσεις και η εφαρμογή της βαθιάς μάθησης υπόσχεται να αναμορφώσει την αξιολόγηση και τη διαχείριση των καρδιακών ανωμαλιών.



Εξετάζοντας πρωτοποριακές μελέτες που χρησιμοποιούν αρχιτεκτονικές όπως τα Convolutional Neural Networks (CNN) αλλά και τα Bidirectional LSTM (BiLSTM)[15], στοχεύουμε να αναδείξουμε τις δυνατότητες αυτών των μοντέλων στην αναγνώριση σύνθετων μοτίβων στα ΗΚΓ. Παρουσιάζοντας τη σύγχρονη συμπεριφορά των αλγορίθμων βαθιάς μάθησης, προσφέρουμε την εικόνα του παρόντος και του μέλλοντος σε αυτό το τομέα.

1.1 Ρόλος Τεχνητής Νοημοσύνης στην Υγεία

Η Τεχνητή Νοημοσύνη (TN) έχει καταστεί σημαντικό εργαλείο στην κλινική διάγνωση[16], αναδιαμορφώνοντας το τοπίο των ιατρικών πρακτικών και διεργασιών. Είναι σημαντικό να σημειωθεί πως η Τεχνητή Νοημοσύνη έχει βοηθήσει σημαντικά στην ανάλυση εικόνων και στην επεξεργασία σήματος[1][17], όπου οι δυνατότητές της έχουν προωθήσει την έγκαιρη και έγκυρη ανίχνευση διαφόρων ασθενειών. Σε αυτό το ευρύτερο πλαίσιο, η TN βοηθά τους ειδικούς στη λήψη τεκμηριωμένων αποφάσεων και μετριάξει τα διαγνωστικά σφάλματα, σηματοδοτώντας μια αλλαγή στον τρόπο με τον οποίο η υγεία θα λειτουργεί στο μέλλον για την πρόληψη και καταπολέμηση ασθενειών.

Η ενσωμάτωση της TN στην κλινική διάγνωση εμφανίζεται σε πληθώρα από ιατρικούς τομείς, παρουσιάζοντας ενθαρρυντικά αποτελέσματα στην αποτελεσματική ανίχνευση ασθενειών που κυμαίνονται από τον καρκίνο έως τις νευρολογικές διαταραχές[18]. Η ικανότητα της τεχνητής νοημοσύνης να αναλύει γρήγορα και με ακρίβεια τεράστια σύνολα δεδομένων, εντοπίζοντας λεπτά μοτίβα και συσχετίσεις μέσα σε πολύπλοκα ιατρικά δεδομένα, τη διακρίνει ως ένα σημαντικό εργαλείο σε συνδυασμό με προυπάρχουσες μεθόδους. Η αποτελεσματικότητα με την οποία η TN επεξεργάζεται τις πληροφορίες επιταχύνει τις διαγνώσεις και επιτρέπει τον σχεδιασμό εξατομικευμένων σχεδίων θεραπείας[2][19], υπογραμμίζοντας τον ρόλο της στην ενίσχυση της συνολικής φροντίδας των ασθενών.

1.2 Καρδιά


Η καρδιά, ένα θαύμα της βιολογικής μηχανικής, είναι ο απαραίτητος ενορχηστρωτής της ζωής μέσα στο ανθρώπινο σώμα. Λειτουργώντας ως μια περίπλοκη αντλία, αυτό το ζωτικό όργανο προωθεί το αίμα σε όλο το κυκλοφορικό σύστημα[20], εδραιώνοντας τη σημασία του στη διατήρηση της συνολικής φυσιολογικής λειτουργίας του σώματος.

Η δυναμική φύση της καρδιάς υπογραμμίζεται από τον διαχωρισμό της σε δύο διακριτές αντλίες - τη δεξιά καρδιά, που κατευθύνει το αίμα προς τους πνεύμονες για οξυγόνωση, και την αριστερή καρδιά, που διοχετεύει το πλούσιο σε οξυγόνο αίμα στα περιφερειακά όργανα του σώματος[21]. Αυτό το συντονισμένο σύνολο συστολών, που ενορχηστρώνεται από τους κόλπους και τις κοιλίες, αποτελεί την ουσία του καρδιακού κύκλου.

Στον πυρήνα της, η θεμελιώδης αποστολή της καρδιάς είναι να κυκλοφορεί αίμα, πλούσιο σε θρεπτικά συστατικά, σε ιστούς που το έχουν ανάγκη, αλλά και η απομάκρυνση των υποπροϊόντων του μεταβολισμού από και προς τους διάφορους ιστούς. Στον πυρήνα αυτής της διαδικασίας είναι ο ρυθμικός καρδιακός κύκλος, που αρχίζει με την αυτόματη παραγωγή ενός δυναμικού δράσης στον φλεβόκομβο. Αξιοσημείωτος είναι ο ρόλος των κόλπων, που λειτουργούν ως προ-αντλίες, επιτρέποντας τη βέλτιστη πλήρωση του αίματος στις κοιλίες πριν η ισχυρή συστολή τους προωθήσει το αίμα μέσω του περίπλοκου αγγειακού δικτύου.¹

Μια προσεκτικότερη εξέταση της ανατομίας της καρδιάς αποκαλύπτει την πολυεπίπεδη πολυπλοκότητά της - από τα μυϊκά τοιχώματα που στεγάζουν το ενδοκάρδιο, το μυοκάρδιο και το επικάρδιο, μέχρι τους χωρισμένους τέσσερις θαλάμους (κόλπους και κοιλίες) που συνδέονται μέσω βαλβίδων για την κυκλοφορία και την κατανομή του αίματος στο σώμα.

¹ <https://my.clevelandclinic.org/health/body/21704-heart>



Εικόνα 1: Ανατομία της Καρδιάς

1.3 Αρρυθμία

Οι αρρυθμίες, ή ανώμαλοι καρδιακοί ρυθμοί, περιλαμβάνουν ένα φάσμα καταστάσεων που αποκλίνουν από τη φυσιολογική ακολουθία ηλεκτρικών παλμών της καρδιάς, διαταράσσοντας τη συντονισμένη αντλητική της δραστηριότητα[22]. Ο φυσικός βηματοδότης της καρδιάς, ο φλεβόκομβος, συνήθως ενορχηστρώνει αυτή τη ρυθμική διαδικασία, αλλά διάφοροι παράγοντες μπορούν να οδηγήσουν σε ανωμαλίες σε αυτή την διαδικασία. Οι ποικίλοι τύποι αρρυθμιών περιλαμβάνουν την κολπική μαρμαρυγή και τον περυσισμό, την βραδυκαρδία, τις διαταραχές αγωγιμότητας, τις πρόωρες συστολές, την ταχυκαρδία, την κοιλιακή μαρμαρυγή και άλλες διαταραχές του ρυθμού. Ενώ ορισμένες αρρυθμίες μπορεί να είναι παροδικές και να επηρεάζουν ελάχιστα τη

συνολική λειτουργία της καρδιάς, παρατεταμένες περιπτώσεις μπορεί να οδηγήσουν σε πολύ αργό, πολύ γρήγορο ή ακανόνιστο καρδιακό ρυθμό, μειώνοντας την αποτελεσματικότητα της άντλησης της καρδιάς.

Τα αίτια των αρρυθμιών είναι πολύπλευρα και περιλαμβάνουν διαταραχές στο ηλεκτρικό σύστημα σηματοδότησης της καρδιάς, δυσλειτουργία του φυσικού βηματοδότη, δομικές αλλαγές στον καρδιακό ιστό και εξωτερικές επιδράσεις όπως υπερβολική άσκηση, άγχος ή παρενέργειες φαρμάκων. Οι διαταραχές του ηλεκτρικού σήματος μπορεί να οδηγήσουν σε καθυστερήσεις ή μπλοκαρίσματα του φυσιολογικού ρυθμού της καρδιάς, ενώ η δυσλειτουργία του φλεβόκομβου μπορεί να έχει ως αποτέλεσμα την ανάληψη των ευθυνών βηματοδότησης από εναλλακτικές περιοχές της καρδιάς. Οι δομικές αλλαγές, είτε λόγω μεταβολών στη ροή του αίματος είτε λόγω βλάβης στο ηλεκτρικό σύστημα της καρδιάς, συμβάλλουν στις αρρυθμίες. Άλλοι παράγοντες που επίσης συμβάλλουν στην πρόκληση αρρυθμιών μπορεί να είναι οι ανισορροπίες στα υγρά, τις ορμόνες και τους ηλεκτρολύτες στο αίμα. Αυτή η περίπλοκη αλληλεπίδραση παραγόντων υπογραμμίζει την πολυπλοκότητα των αρρυθμιών και τονίζει τη σημασία της κατανόησης των τύπων και των αιτιών τους για την αποτελεσματική διάγνωση και διαχείριση τέτοιων καταστάσεων με στόχο την προαγωγή της καρδιαγγειακής υγείας.²

Η εξέλιξη της ανίχνευσης αρρυθμιών με την πάροδο των ετών χαρακτηρίστηκε από σημαντικές εξελίξεις στις τεχνολογίες απομακρυσμένης διαχείρισης και την ενσωμάτωση της τεχνητής νοημοσύνης στην υγειονομική περίθαλψη. Ειδικότερα, η έρευνα σχετικά με το πρόγραμμα REM HF[23] που διεξήχθη σε ασθενείς με καρδιακή ανεπάρκεια με εμφυτευμένες συσκευές ανέδειξε τις δυνατότητες της εξ αποστάσεως παρακολούθησης για τον εντοπισμό της κολπικής μαρμαρυγής (KM). Μεταγενέστερες αναλύσεις υπογράμμισαν τα οφέλη της τηλεπαρακολούθησης όσον αφορά την έγκαιρη ανίχνευση της AF, την βελτιστοποίηση του τρόπου λειτουργίας νοσοκομειακών εγκαταστάσεων και τη διαχείριση δεδομένων με στόχο τον εξιχνασμό των διαδικασιών[36]. Ωστόσο, εξακολουθούν να υπάρχουν προκλήσεις, ιδίως όσον αφορά την κατανόηση των επιπτώσεων της σιωπηλής AF που ανιχνεύεται μέσω της απομακρυσμένης παρακολούθησης του ΗΚΓ και της πιθανής συσχέτισής της με τον κίνδυνο εγκεφαλικού επεισοδίου. Το δυναμικό τοπίο της ανίχνευσης αρρυθμιών


² <https://www.heart.org/en/health-topics/arrhythmia/about-arrhythmia>

αντανακλά μια συνεχή αναζήτηση για την τελειοποίηση των τεχνολογιών παρακολούθησης και την κατανόηση της κλινικής σημασίας των ανιχνευόμενων συμβάντων αρρυθμίας.[3]

1.3.1 Ηλεκτροκαρδιογράφημα – ECG (ΗΚΓ)

Το ηλεκτροκαρδιογράφημα (ΗΚΓ) είναι μια ιατρική διαγνωστική εξέταση που καταγράφει την ηλεκτρική δραστηριότητα της καρδιάς κατά τη διάρκεια συγκεκριμένης διάρκειας[24]. Περιλαμβάνει την τοποθέτηση ηλεκτροδίων στο δέρμα για την ανίχνευση και τη μέτρηση των ηλεκτρικών παλμών της καρδιάς, παρέχοντας κρίσιμες πληροφορίες για τον ρυθμό και τη λειτουργικότητά της. Τα ΗΚΓ έχουν καθοριστική σημασία για τη διάγνωση ποικίλων καρδιακών παθήσεων, όπως οι αρρυθμίες και η ισχαιμία.³ [4]

³ <https://www.nhs.uk/conditions/electrocardiogram/>



Εικόνα 2: Παράδειγμα ECG

Η ενσωμάτωση της Τεχνητής Νοημοσύνης (TN) στην ταξινόμηση των ΗΚΓ[25][5] έχει αναδειχθεί ως ζωτικής σημασίας πρόοδος στην ιατρική τεχνολογία για διάφορους λόγους:

1. **Ενισχυμένη αποτελεσματικότητα:** Οι αλγόριθμοι TN επιτρέπουν την ταχεία και ακριβή ανάλυση των δεδομένων ΗΚΓ, μειώνοντας σημαντικά τον χρόνο και τη χειροκίνητη προσπάθεια που απαιτείται για την ερμηνεία. Αυτή η αποτελεσματικότητα είναι ιδιαίτερα πολύτιμη σε σενάρια ευαίσθητου χρόνου, διευκολύνοντας την άμεση διάγνωση και παρέμβαση.
2. **Έγκαιρος εντοπισμός:** Η τεχνητή νοημοσύνη συμβάλλει στην έγκαιρη ανίχνευση παρατυπιών στα μοτίβα του ΗΚΓ, υποδεικνύοντας ενδεχομένως υποκείμενα καρδιακά προβλήματα. Η έγκαιρη αναγνώριση επιτρέπει έγκαιρες ιατρικές

παρεμβάσεις, οδηγώντας σε βελτιωμένα αποτελέσματα για τους ασθενείς και ενισχυμένη διαχείριση της νόσου.

3. **Χειρισμός μεγάλων δεδομένων:** Με την κλιμάκωση του όγκου των ιατρικών δεδομένων, ιδίως των συνόλων δεδομένων ΗΚΓ[7], η TN υπερέχει στην αποτελεσματική διαχείριση και ερμηνεία εκτεταμένων πληροφοριών. Αυτή η ικανότητα είναι καθοριστικής σημασίας για την αποκάλυψη λεπτών μοτίβων και τάσεων που μπορεί να διαφεύγουν της ανθρώπινης παρατήρησης.
4. **Συνεπής ανάλυση:** Οι αλγόριθμοι TN παρέχουν συνεπή και τυποποιημένη ανάλυση ΗΚΓ, ελαχιστοποιώντας τη διακύμανση στην ερμηνεία μεταξύ διαφορετικών επαγγελματιών υγείας. Αυτή η συνέπεια είναι ζωτικής σημασίας για τη διασφάλιση της ακρίβειας και της αξιοπιστίας των διαγνώσεων.
5. **Υποστήριξη λήψης αποφάσεων:** Η TN χρησιμεύει ως πολύτιμο εργαλείο, προσφέροντας συμπληρωματικές γνώσεις και υποστήριξη αποφάσεων στους παρόχους υγειονομικής περίθαλψης[6]. Όπως αναφέραμε και προηγούμενως, η δυνατότητα των μοντέλων μηχανικής και βαθιάς μάθησης να ανιχνεύουν τάσεις και συνδέσεις στα δεδομένα εξυπηρετεί ιδιαίτερα στις αποφάσεις των ειδικών για πρόληψη και αντιμετώπιση παθήσεων.
6. **Βελτιστοποίηση πόρων:** Αυτοματοποιώντας εργασίες ρουτίνας όπως η ανάλυση ΗΚΓ, η TN βοηθά τους παρόχους υγειονομικής περίθαλψης να βελτιστοποιήσουν τους πόρους τους. Αυτό επιτρέπει στους επαγγελματίες να επικεντρωθούν στην εξατομικευμένη φροντίδα των ασθενών και να αντιμετωπίσουν πιο σύνθετες περιπτώσεις, βελτιώνοντας τελικά τη συνολική παροχή υγειονομικής περίθαλψης.

1.4 Σχετική Έρευνα

Ο τομέας της ταξινόμησης των αρρυθμιών με τη μελέτη ηλεκτροκαρδιογραφήματος (ΗΚΓ), επιφέρει σημαντικές ερευνητικές ανακαλύψεις. Πρωτοποριακές μελέτες, όπως η μελέτη των Rajpurkar et al. με τίτλο "Cardiologist-level arrhythmia detection with convolutional neural networks"[8], κατέδειξαν την αποτελεσματικότητα των αρχιτεκτονικών βαθιάς μάθησης στην αυτόματη ανίχνευση και ταξινόμηση των αρρυθμιών του ΗΚΓ. Η αξιοποίηση των νευρωνικών δικτύων συνελιζέων (CNNs) και των επαναλαμβανόμενων νευρωνικών δικτύων (RNNs) επέτρεψε την εξαγωγή

περίπλοκων χαρακτηριστικών από ακατέργαστα σήματα ΗΚΓ, ξεπερνώντας τις παραδοσιακές μεθόδους σε ακρίβεια και αποτελεσματικότητα.

Παρά τα σημαντικά βήματα προόδου, εξακολουθούν να υπάρχουν προκλήσεις στην ανάπτυξη και την εφαρμογή μοντέλων τεχνητής νοημοσύνης για την ταξινόμηση των αρρυθμιών του ΗΚΓ. Ειδικότερα, η ανησυχία για την ιδιωτικότητα των δεδομένων του πληθυσμού[27] και η μεροληψία[29] ή προκατάληψη[28] των μοντέλων αυτών διεγείρουν σημαντικά ερωτήματα. Επιπλέον, η απουσία ερμηνευσιμότητας και επεξηγηματικότητας των μοντέλων τεχνητής νοημοσύνης δημιουργούν ανησυχίες για την κλινική υιοθέτησή τους[26]. Η εργασία των Caruana κ.ά. με τίτλο "Intelligible models for healthcare"[9], η οποία κάνει λόγο για τη σημασία των ερμηνεύσιμων μοντέλων, υπογραμμίζει την ανάγκη για συνεχή έρευνα σε αυτόν τον τομέα, ώστε να ενισχυθεί η αξιοπιστία των εφαρμογών ΤΝ σε πραγματικές ιατρικές συνθήκες. Καθώς ο τομέας συνεχίζει να εξελίσσεται, η αντιμετώπιση αυτών των προκλήσεων θα είναι καθοριστικής σημασίας για την αξιοποίηση όλων των δυνατοτήτων της ΤΝ στην επανάσταση της διάγνωσης και της θεραπείας των αρρυθμιών του ΗΚΓ.

2


Υλικό και Μέθοδοι

Στην ενότητα αυτή παρουσιάζεται το θεωρητικό υπόβαθρο της μελέτης. Γίνεται αναλυτική περιγραφή του τρόπου διεξαγωγής των πειραμάτων και της διαδικασίας συλλογής των δεδομένων και επεξηγούνται οι αλγόριθμοι επεξεργασίας των δεδομένων και οι μέθοδοι αξιολόγησης των αποτελεσμάτων.

2.1 Νευρωνικά Δίκτυα

2.1.1 Τεχνητά Νευρωνικά Δίκτυα

Τα Τεχνητά Νευρωνικά Δίκτυα (Artificial Neural Networks-ANN) είναι υπολογιστικά συστήματα εμπνευσμένα από τον τρόπο λειτουργίας του εγκεφάλου του ανθρώπου. Αποτελούνται από διασυνδεδεμένους κόμβους που ονομάζονται νευρώνες, οι οποίοι συνεργάζονται για την επεξεργασία πληροφοριών και τη βελτιστοποίηση της τελικής εξόδου. Τα ANN έχουν συνήθως ένα επίπεδο εισόδου που λαμβάνει πολυδιάστατα διανύσματα τα οποία με την σειρά τους διανύουν το δίκτυο μέσω κρυφών επιπέδων. Αυτά τα κρυφά επίπεδα λαμβάνουν αποφάσεις με βάση την είσοδο που δέχονται και προσαρμόζουν τις εσωτερικές τους παραμέτρους για να βελτιώσουν την έξοδο. Η διαδικασία αυτή είναι γνωστή σαν μάθηση. Όταν ένα ANN έχει πολλαπλά κρυφά στρώματα, είναι γνωστό ως μοντέλο βαθιάς μάθησης ("deep learning") [10]. Η σχηματική αναπαράσταση της βασικής αρχιτεκτονικής των ANN φαίνεται στην Εικόνα 3.



Εικόνα 3: Βασική Αρχιτεκτονική ANN

2.1.2 Συνελικτικά Νευρωνικά Δίκτυα (CNNs):

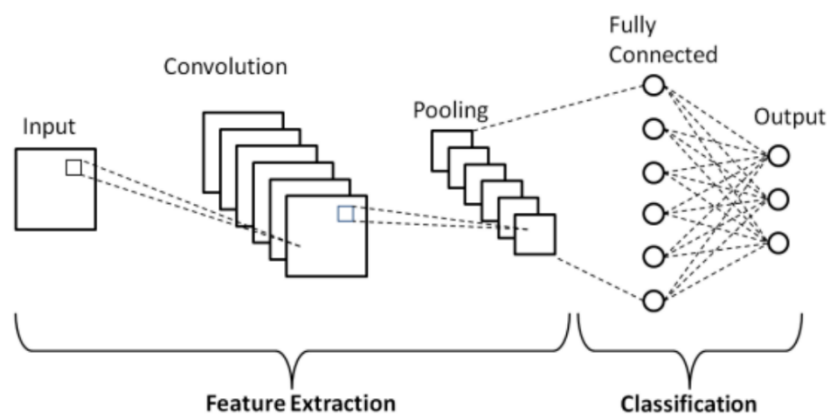
Τα CNN μοιράζονται ομοιότητες με τα παραδοσιακά ANN στο ότι αποτελούνται από νευρώνες που μαθαίνουν και βελτιστοποιούν τον εαυτό τους για να παίρνουν καλύτερες αποφάσεις. Κάθε νευρώνας δέχεται μία είσοδο και εκτελεί λειτουργίες πάνω στα στρώματά ώστε ο συνδυασμός των υπολογισμών να αποτελέσει την έξοδο του δικτύου. Ξεκινώντας από ακατέργαστα διανύσματα εικόνας ως είσοδο και καταλήγοντας σε ταξινομήσεις κλάσεων ως έξοδο, ολόκληρο το δίκτυο αναπαριστά μια ενιαία συνάρτηση ταξινόμησης σε συγκεκριμένες κλάσεις δεδομένων[10]. Το τελικό στρώμα ενός CNN είναι υπεύθυνο για την λήψη της απόφασης που κάνει το δίκτυο σχετικά με την ταξινόμηση μίας εικόνας ή ενός κομματιού μίας εικόνας. Το αποτέλεσμα των δικτύων αυτών συνήθως είναι μία πιθανότητα η οποία εκφράζει την σιγουριά του δικτύου ότι ένα αποτέλεσμα ανήκει σε μία συγκεκριμένη κλάση και η τελική του απόφαση είναι η κλάση εκείνη η οποία συνδέεται με την μεγαλύτερη πιθανότητα. Οι τεχνικές και οι στρατηγικές που αναπτύχθηκαν για τα παραδοσιακά

ANN μπορούν ακόμη να εφαρμοστούν. Η βασική διάκριση μεταξύ των CNN και των παραδοσιακών ANN είναι ότι τα CNN χρησιμοποιούνται κυρίως για εργασίες αναγνώρισης προτύπων που αφορούν εικόνες και σήματα. Η αρχιτεκτονική τους τους επιτρέπει να συλλάβουν και να αντιληφθούν την ύπαρξη περίπλοκων χαρακτηριστικών τα οποία εκφράζουν ιδιότητες μίας εικόνας. Τέτοια χαρακτηριστικά μπορεί ενδεικτικά να είναι το χρώμα και η υφή της εικόνας. Αυτή η ιδιότητα των CNN τα καθιστά εξαιρετικά κατάλληλα για τέτοιες διεργασίες. Μία ακόμη σημαντική ιδιότητα την οποία κατέχουν τα CNN λόγω της αρχιτεκτονικής και του τρόπου λειτουργίας τους είναι ότι έχουν σαφέστερα μικρότερο αριθμό παραμέτρων από τα ANN δίκτυα τα οποία υλοποιούνται για παρόμοιες διεργασίες και ταξινομήσεις.

2.1.2.1 Αρχιτεκτονική Συνελκτικών Νευρωνικών Δικτύων

Η αρχιτεκτονική των CNN αποτελείται από τα εξής στρώματα: τα συνελκτικά στρώματα (convolutional layers) , τα στρώματα συγκέντρωσης (pooling layers) και τα πλήρως συνδεδεμένα στρώματα (dense layers). Θα επιχειρήσουμε παρακάτω να αναλύσουμε την λειτουργία του κάθε στρώματος:


1. Το στρώμα εισόδου περιέχει τις τιμές των pixels της εικόνας.
2. Στο στρώμα συνελίξεων, οι νευρώνες συνδέονται με τοπικές περιοχές της εισόδου. Η έξοδος αυτού του στρώματος προκύπτει από το εξωτερικό γινόμενο φίλτρων ή πυρήνων, που χρησιμοποιούνται για την εξαγωγή χρήσιμων χαρακτηριστικών ταξινόμησης, και της εισόδου.
3. Στο στρώμα pooling εκτελείται υποδειγματοληψία του αποτελέσματος από το στρώμα συνελίξεως με σκοπό τη μείωση του αριθμού των παραμέτρων και την διατήρηση των πιο σημαντικών χαρακτηριστικών της εικόνας.
4. Τα πλήρως συνδεδεμένα στρώματα, με παρόμοιο τρόπο με τα τυπικά ANN, παράγουν βαθμολογίες κλάσεων για την ταξινόμηση.



Εικόνα 4: CNN Layers

2.1.2.2 Convolutional Layer

Το στρώμα συνέλιξης (convolutional layer) είναι ο πυρήνας της λειτουργίας των CNN. Οι βασικές του παράμετροι περιστρέφονται γύρω από τη χρήση φίλτρων ή πυρήνων μάθησης (filters ή kernels), οι οποίοι εξυπηρετούν στην εξαγωγή των χρήσιμων χαρακτηριστικών που εκφράζουν την εικόνα ή το σήμα όπως είπαμε και προηγουμένως. Όταν τα δεδομένα περνούν από ένα επίπεδο συνέλιξης, γίνεται συνέλιξη μεταξύ της εισόδου και του φίλτρου. Το φίλτρο ουσιαστικά διανύει όλη την είσοδο βηματικά από πάνω αριστερά μέχρι κάτω δεξιά, και κάθε φορά από την συνέλιξη του τμήματος της εικόνας και του φίλτρου προκύπτει μία τιμή η οποία τοποθετείται σε έναν πίνακα ο οποίος είναι με την σειρά του αποτέλεσμα που δίνει το στρώμα συνέλιξης στο στρώμα pooling. Ο πίνακας αυτός ονομάζεται χάρτης χαρακτηριστικών (feature map). Αυτή η διαδικασία γίνεται για κάθε φίλτρο και τα αποτελέσματα των συνελίξεων μεταξύ εισόδου και εκάστου φίλτρου στοιβάζονται το ένα μετά το άλλο ώστε να προχωρήσουν στα επόμενα στρώματα. Η διαδικασία συνέλιξης φαίνεται στο παρακάτω σχήμα της Εικόνα 5.



Εικόνα 5: Χάρτες Χαρακτηριστικών

Αυτή η διαδικασία είναι ουσιαστικά ο τρόπος με τον οποίο το δίκτυο καταφέρνει να μάθει τα διάφορα χαρακτηριστικά της εικόνας ή του σήματος τα οποία την κάνουν διαφορετική από άλλες. Τα φίλτρα αλλάζουν ανάλογα με τις ανάγκες της ταξινόμησης και τα συγκεκριμένα χαρακτηριστικά που αναζητά ο εκάστοτε ερευνητής. Σημαντικό είναι να προσθέσουμε ότι η συνελεκτική διαδικασία εξαρτάται από την ταχύτητα ή βήμα, γνωστό και ως stride, με το οποίο διανύει το φίλτρο την εικόνα αλλά και το μέγεθος του φίλτρου που τοποθετείται πάνω στην εικόνα. Λόγω της φύσης της συνελίξεως, το αποτέλεσμα που τοποθετείται στον χάρτη χαρακτηριστικών θα μπορεί να είναι μία περιστροφή, αν το φίλτρο μας είναι αυτού του τύπου, ένας μέσος όρος ή μία αλλαγή του χρώματος.

Εδώ είναι σημαντικό να σημειωθεί ότι φαίνεται και η πραγματική δύναμη αυτών των δικτύων έναντι των ANN. Ανάλογα με τον αριθμό των φίλτρων ή πυρήνων η εκπαίδευση μοντέλων ANN σε εισόδους εικόνας αντιμετωπίζει συχνά προκλήσεις λόγω του μεγάλου μεγέθους του μοντέλου και τον μεγάλο αριθμό παραμέτρων που χρειάζεται για να επιτύχει το ίδιο αποτέλεσμα που θα πετύχαινε ένα CNN. Αυτό προκαλείται κυρίως από την πλήρως συνδεδεμένη φύση των τυπικών νευρώνων ANN. Για τον περιορισμό αυτού του προβλήματος, κάθε νευρώνας σε ένα στρώμα συνελεκτικού τύπου συνδέεται μόνο με μια μικρή περιοχή του όγκου εισόδου και λαμβάνει από εκείνη την περιοχή την είσοδο που χρειάζεται.

Για να καταστήσουμε σαφές το πρόβλημα που αντιμετωπίζουν τα ANN και πως τα CNN έρχονται για να το αντιμετωπίσουν, ας πάρουμε ως παράδειγμα μία είσοδο ενός δικτύου σε μορφή εικόνας RGB $64 \times 64 \times 3$ (με διαστάσεις 64×64). Το μέγεθος του πυρήνα θα το ορίσουμε ίσο με 6×6 . Έτσι κάθε νευρώνας μέσα στο στρώμα συνέλιξης θα έχει συνολικά 108 βάρη δηλαδή $6 \times 6 \times 3$, όπου το 3 αντιπροσωπεύει το βάθος της

εικόνας καθώς η εικόνα χαρακτηρίζεται από τρία διαφορετικά χρώματα. Στην περίπτωση ενός ANN ο αριθμός των παραμέτρων για την συγκεκριμένη αρχιτεκτονική θα ανερχόταν στις 12.288 [7]. Αυτό είναι σαφές πως θα είχε επιπτώσεις στην απόδοση και στους χρόνους εκτέλεσης του δικτύου για μάθηση και έλεγχο επιδόσεων, επομένως καθίσταται σαφής η χρησιμότητα των συνελεκτικών δικτύων για αυτά τα είδη εισόδων.

2.1.2.3 Pooling Layer

Τα στρώματα pooling χρησιμοποιούνται στα CNN για τη σταδιακή μείωση της διάστασης της αναπαράστασης, μειώνοντας, κατ' αυτό το τρόπο, τον αριθμό των παραμέτρων και την υπολογιστική πολυπλοκότητα του μοντέλου. Αυτά τα στρώματα λειτουργούν σε κάθε χάρτη εντός της εισόδου και μειώνουν τη διάστασή του χρησιμοποιώντας τη συνάρτηση "MAX". Στα περισσότερα CNN, χρησιμοποιούνται συνήθως στρώματα max pooling, τα οποία χρησιμοποιούν πυρήνες 2×2 με βήμα 2 κατά μήκος των χωρικών διαστάσεων της εισόδου. Με τον τρόπο αυτό ο χάρτης ενεργοποίησης μειώνεται στο 25% του αρχικού του μεγέθους, ενώ ο όγκος βάθους διατηρείται στο τυπικό του μέγεθος. Το max pooling χρησιμοποιεί συνήθως δύο προσεγγίσεις. Τα στρώματα αυτά ορίζονται συνήθως με stride ίσο με τη μονάδα και φίλτρα μεγέθους 2×2 , επιτρέποντάς τους να καλύπτουν ολόκληρη τη χωρική διάσταση της εισόδου χωρίς να την διανύουν εξαιρετικά γρήγορα χάνοντας έτσι κάποια από την πληροφορία. Γενικά παρατηρείται ότι η χρήση μεγάλων φίλτρων και γρήγορης διάσχυσης της εικόνας συχνά μειώνει σημαντικά την απόδοση και την αποτελεσματικότητα του μοντέλου να εξάγει τα απαραίτητα χαρακτηριστικά για την ταξινόμηση της εικόνας το οποίο έχει ως αποτέλεσμα το μοντέλο να μην φέρνει καλά αποτελέσματα.

2.1.2.4 Fully Connected Layer

Το πλήρως συνδεδεμένο στρώμα αποτελείται από νευρώνες που συνδέονται άμεσα με τους νευρώνες στα δύο γειτονικά στρώματα με τρόπο όμοια της διάταξης ενός ANN δικτύου. Σε αυτό το στρώμα, κάθε νευρώνας συνδέεται με όλους τους νευρώνες του προηγούμενου στρώματος και με όλους τους νευρώνες του επόμενου στρώματος. Αυτή η πλήρως συνδεδεμένη αρχιτεκτονική επιτρέπει την ολοκληρωμένη ανταλλαγή πληροφοριών μεταξύ των στρωμάτων, επιτρέποντας στο δίκτυο να μαθαίνει πολύπλοκα μοτίβα και σχέσεις. Το πλήρως συνδεδεμένο στρώμα διαδραματίζει

κρίσιμο ρόλο στα τελικά στάδια του δικτύου, συνδυάζοντας τα χαρακτηριστικά που όρισαν τα συνελεκτικά στρώματα με την τελική ταξινόμηση την οποία δεν είναι ικανά να κάνουν τα συνελεκτικά και τα pooling στρώματα του δικτύου.

2.1.3 BiLSTM

Τα Bidirectional Long Short-Term Memory (BiLSTM) έχουν αναδειχθεί ως ένα σημαντικό εργαλείο στον τομέα της τεχνητής νοημοσύνης, ιδίως για εργασίες που περιλαμβάνουν διαδοχικά δεδομένα, όπως η ταξινόμηση των αρρυθμιών ηλεκτροκαρδιογραφήματος (ΗΚΓ). Επεκτείνοντας τις δυνατότητες των παραδοσιακών αρχιτεκτονικών LSTM, η BiLSTM επιτρέπει την ταυτόχρονη εξέταση πληροφοριών του παρελθόντος και του μέλλοντος με την επεξεργασία δεδομένων τόσο προς τα εμπρός όσο και προς τα πίσω. [11]

Αυτή η αμφίδρομη προσέγγιση ενισχύει την ικανότητα του μοντέλου να συλλαμβάνει σύνθετες χρονικές εξαρτήσεις, καθιστώντας το κατάλληλο για εργασίες όπου η κατανόηση της διαδοχικής σειράς των γεγονότων είναι ζωτικής σημασίας, όπως στη δυναμική ανάλυση των σημάτων ΗΚΓ.[12]

Στο συγκεκριμένο πλαίσιο της ταξινόμησης των αρρυθμιών, τα δίκτυα BiLSTM προσφέρουν μια ισχυρή λύση για την αποκρυπτογράφηση περίπλοκων μοτίβων που ενσωματώνονται σε δεδομένα χρονοσειρών ΗΚΓ[12]. Καταγράφοντας αποτελεσματικά τις εξαρτήσεις και προς τις δύο κατευθύνσεις, το BiLSTM αποδεικνύεται ιδιαίτερα ικανό στη διάκριση ανεπαίσθητων αλλαγών στον καρδιακό ρυθμό που υποδηλώνουν διάφορες αρρυθμίες. Έχει αναδειχθεί η επιτυχία της εφαρμογής των αρχιτεκτονικών BiLSTM στην επίτευξη κορυφαίων επιδόσεων για την ταξινόμηση ΗΚΓ, υπογραμμίζοντας την αποτελεσματικότητά τους στη διαχείριση των ιδιαιτεροτήτων των καρδιακών σημάτων.

2.2 Σύνολο Δεδομένων προς Ανάλυση

Το Dataset που χρησιμοποιήθηκε προσφέρεται δωρεάν από το Physionet.org και προέρχεται από τα εργαστήρια του νοσοκομείο Βοστώνης Beth Israel και το Πανεπιστήμιο MIT. Ονομάζεται MIT-BIH Arrhythmia Database.

Το Dataset αυτό περιέχει 48 λήψεις των μισών της ώρας η κάθε μία, από δύο κανάλια τα οποία κάνουν μετρήσεις ηλεκτροκαρδιογραφήματος και προέρχεται από 47 ασθενείς. Οι 23 ασθενείς επιλέχθηκαν τυχαία από μείγμα πληθυσμού και κατά 60% ήταν ασθενείς του νοσοκομείου, ενώ κατά 40% όχι. Οι υπόλοιποι 24 επιλέχθηκαν συγκεκριμένα για την κλινικά σημαντική αρρυθμία που έδειξαν. Κάθε λήψη ψηφιοποιήθηκε στα 360 δείγματα ανά second, με 11 bit resolution σε μία κλίμακα των 10mV. Δύο ή περισσότεροι καρδιολόγοι είναι υπεύθυνοι για τις επισημειώσεις των λήψεων.⁴

2.3 Πειραματική Διαδικασία

Αφού έγινε λήψη των δεδομένων, αυτά μετασχηματίστηκαν με τέτοιο τρόπο ώστε να γίνεται δυνατή η υλοποίηση της μελέτης μας. Πιο συγκεκριμένα, τα δεδομένα για κάθε ασθενή βρίσκονται σε 4 αρχεία τα οποία είναι της μορφής atr, dat, hea και xws. Αφού διαβάστηκαν με χρήση κατάλληλων βιβλιοθηκών της Python, χωρίστηκαν κατά κτύπους (beats) και ορίστηκαν οι επισημειώσεις για κάθε κτύπο. Οι επισημειώσεις για το παρόν πείραμα ορίστηκαν ως “Συνηθισμένες” (“Normal”) και “Ασυνήθιστες” (“Abnormal”) καθώς θα ακολουθήσει δυαδική ταξινόμηση. Χρειάστηκε να προστεθεί padding των 300 σημείων σε όλους τους κτύπους για να μπορούν να ορισθούν features για την διαδικασία μάθησης και για να επιτευχθεί η ομοιομορφία στα δεδομένα εισόδου του πειράματος. Τέλος, κανονικοποιήθηκαν τα δεδομένα.

Για τις επισημειώσεις εκείνες που ορίστηκαν ως “Ασυνήθιστες” χρησιμοποιήθηκε η τεχνική της επαύξησης δεδομένων ώστε προκύψουν ισάριθμες επισημειώσεις “Συνηθισμένων” και μη χτύπων. Το εργαλείο για την επαύξηση ήταν ο θόρυβος Gauss για κάθε feature σε ένα κτύπο, προσθαφαιρέθηκαν δηλαδή πολύ μικρές αλλαγές στις

⁴ <https://www.physionet.org/content/mitdb/1.0.0/>

τιμές των μετρήσεων με σκοπό την υλοποίηση ενός μοντέλου που αντιλαμβάνεται καλύτερα την αρρυθμία με πληθώρα δεδομένων. Στη συνέχεια, έγινε διαχωρισμός των δεδομένων σε δεδομένα εκπαίδευσης, επικύρωσης και δοκιμής.

1. **Δεδομένα εκπαίδευσης** (Training Set) ονομάζονται τα δεδομένα που χρησιμοποιούνται για την εκπαίδευση ενός μοντέλου μηχανικής μάθησης ή νευρωνικού δικτύου, με σκοπό την εκμάθηση των χαρακτηριστικών και των συσχετίσεων των δεδομένων.
2. **Δεδομένα επικύρωσης** (Validation Set) ονομάζονται τα δεδομένα που χρησιμοποιούνται για την επικύρωση της εκμάθησης του μοντέλου κατά την εκπαίδευση. Γίνεται χρήση αυτού του συνόλου προς αποφυγή υπερπροσαρμογής των δεδομένων στο σύνολο εκπαίδευσης, με σκοπό την καλύτερη γενίκευση του μοντέλου στα επόμενα στάδια.
3. **Δεδομένα δοκιμής** (Testing Set) ονομάζονται τα δεδομένα που χρησιμοποιούνται για την δοκιμή του μοντέλου μετά την ολοκλήρωση της εκπαίδευσής του.

Η εκπαίδευση έγινε με χρήση 20 εποχών με πρόωρη παύση ή early stoppage όπως συνηθίζεται (παύση της εκπαίδευσης του μοντέλου στην περίπτωση όπου δεν επιτυγχθεί το επιθυμητό αποτέλεσμα στο validation set) και πολλαπλές παραμετροποιήσεις τριών μοντέλων τα οποία υλοποιήθηκαν μετά την μελέτη της βιβλιογραφίας.

2.3.1 Υλοποίηση Μοντέλου

Η επιλογή του συγκεκριμένου νευρωνικού δικτύου βασίστηκε στη γνώση της ικανότητας αυτού να επιτυγχάνει ικανοποιητικά αποτελέσματα.

Υλοποιήθηκε υλοποιηθεί ένα 1D Convolutional Neural Network, το οποίο μετά από 2 ή 4 επίπεδα CNN και Pooling επιπέδων συνδέεται σε ένα πλήρως συνδεδεμένο (Feed Forward) Neural Network. Σε αυτό το σημείο, έγινε χρήση της τεχνικής “dropout” για γρηγορότερα αποτελέσματα και αποφυγή overfitting.

Η τεχνική του “dropout” απενεργοποιεί τυχαία νευρώνες, τόσο στα στρώματα εισόδου όσο και στα κρυφά στρώματα κατά τη διάρκεια της εκπαίδευσης, δημιουργώντας ένα σύνολο μικρότερων δικτύων μέσα στο μεγαλύτερο μοντέλο. Με την “απόρριψη”


νευρώνων, το μοντέλο αναγκάζεται να διαφοροποιήσει την προσέγγιση μάθησης, αποτρέποντας την προσκόλληση σε συγκεκριμένα χαρακτηριστικά.

Υλοποιήθηκαν, επίσης, πολλαπλές υπερπαραμετροποιήσεις στο παρόν δίκτυο αλλάζοντας τον αριθμό των φίλτρων, του μεγέθους του πυρήνα και τον αριθμό των κόμβων στο πλήρως συνδεδεμένο δίκτυο. Επιτεύχθηκαν σημαντικά αποτελέσματα της τάξης του 0.92 test accuracy.

Πιο συγκεκριμένα, χρησιμοποιήθηκε η βιβλιοθήκη Keras για την υλοποίηση του μοντέλου. Τα δεδομένα εισόδου τοποθετούνται σε ένα συνελεκτικό στρώμα μίας διάστασης, μεγέθους 300x1 καθώς χρησιμοποιούμε zero padded δεδομένα μεγέθους 300. Ο αριθμός των στρωμάτων συνέλιξης (num_conv_layers) εξαρτάται από τη μεταβλητή num_conv_layers. Κάθε στρώμα συνέλιξης έχει διαφορετικό αριθμό φίλτρων (filters) που αυξάνονται εκθετικά με τον διαίροντα παράγοντα 2^i , όπου i είναι ο αριθμός του στρώματος. Το μέγεθος του πυρήνα (kernel) για τη συνέλιξη ορίζεται από τη μεταβλητή kernel_size. Η ενεργοποίηση (activation) που χρησιμοποιείται είναι η ReLU.

Μετά από κάθε στρώμα συνέλιξης ακολουθεί ένα στρώμα υποδειγματοληψίας (MaxPooling1D) που μειώνει τη διάσταση των χαρακτηριστικών. Αργότερα τα χαρακτηριστικά εξόδου των στρωμάτων “απλώνονται” σε ένα πίνακα ώστε να μπορούν να περαστούν στο πλήρως συνδεδεμένο επίπεδο για να γίνει τελικά η ταξινόμηση. Η τελική ενεργοποίηση στο τελευταίο dense layer είναι η σιγμοειδής για δυαδική ταξινόμηση. Χρησιμοποιείται ο βελτιστοποιητής Adam με την τιμή ρυθμού μάθησης που ορίζεται από τη μεταβλητή learning_rate. Η εκπαίδευση γίνεται με τη χρήση των δεδομένων εκπαίδευσης (X_train, y_train) και επικύρωσης (X_val, y_val). Μπορεί να χρησιμοποιηθεί early stopping (use_early_stopping) για να σταματήσει η εκπαίδευση αν η απώλεια στα δεδομένα επικύρωσης δεν βελτιώνεται για έναν ορισμένο αριθμό εποχών (patience).

Επίσης έγινε μία προσπάθεια επέκτασης των υλοποιήσεων με χρήση δικτύων BiLSTM και συνδυασμό του 1D CNN και BiLSTM η οποία όμως δεν κατάφερε σημαντικά αποτελέσματα και γι' αυτό η υλοποίηση παρέμεινε στο 1D CNN.



Εικόνα 6: Αρχιτεκτονική CNN που χρησιμοποιήσαμε

3

Αποτελέσματα

3.1 Αξιολόγηση Συστήματος για διάφορες τιμές

Υπερπαραμέτρων

Θα αναλυθούν τα προκύπτοντα αποτελέσματα αξιολόγησης και θα σημειωθούν οι επιδράσεις της αλλαγής κάθε υπερπαραμέτρου στις διάφορες μετρικές απόδοσης (Accuracy, Recall, F1 και άλλα).

1. Αριθμός Φίλτρων:

Η αύξηση του αριθμού των φίλτρων βελτιώνει γενικά την απόδοση σε όλες τις μετρικές. Αυτό συμβαίνει επειδή ένας μεγαλύτερος αριθμός φίλτρων επιτρέπει στο μοντέλο να αναγνωρίζει πιο πολύπλοκα χαρακτηριστικά και μοτίβα στα δεδομένα. Ο υψηλότερος αριθμός φίλτρων φαίνεται να συνεισφέρει σε βελτιωμένες μετρικές καθολικά.

2. Μέγεθος Πυρήνα:

Τα μικρότερα μεγέθη πυρήνα (π.χ., `kernel_size_4` και `kernel_size_5`) φαίνεται να έχουν ελαφρώς καλύτερη απόδοση από ότι τα μεγαλύτερα. Αυτό συμβαίνει πιθανώς διότι οι μικρότεροι πυρήνες διακρίνουν λεπτομέρειες στα δεδομένα.

3. Αριθμός Πυκνών Μονάδων (Dense Units):

Τα μοντέλα με υψηλότερο αριθμό μονάδων στην πυκνή στρώση (π.χ., `dense_units_256` και `dense_units_512`) εμφανίζουν γενικά καλύτερη απόδοση. Αυτό υποδηλώνει ότι ένα πιο πολύπλοκο όριο απόφασης είναι ωφέλιμο για αυτό το task. Ωστόσο, πολύ υψηλές μονάδες πυκνής στρώσης (`dense_units_1024`) μπορεί να οδηγήσουν σε υπερεκπαίδευση, όπως φαίνεται από τη μείωση της ακρίβειας.

4. Ρυθμός Dropout:

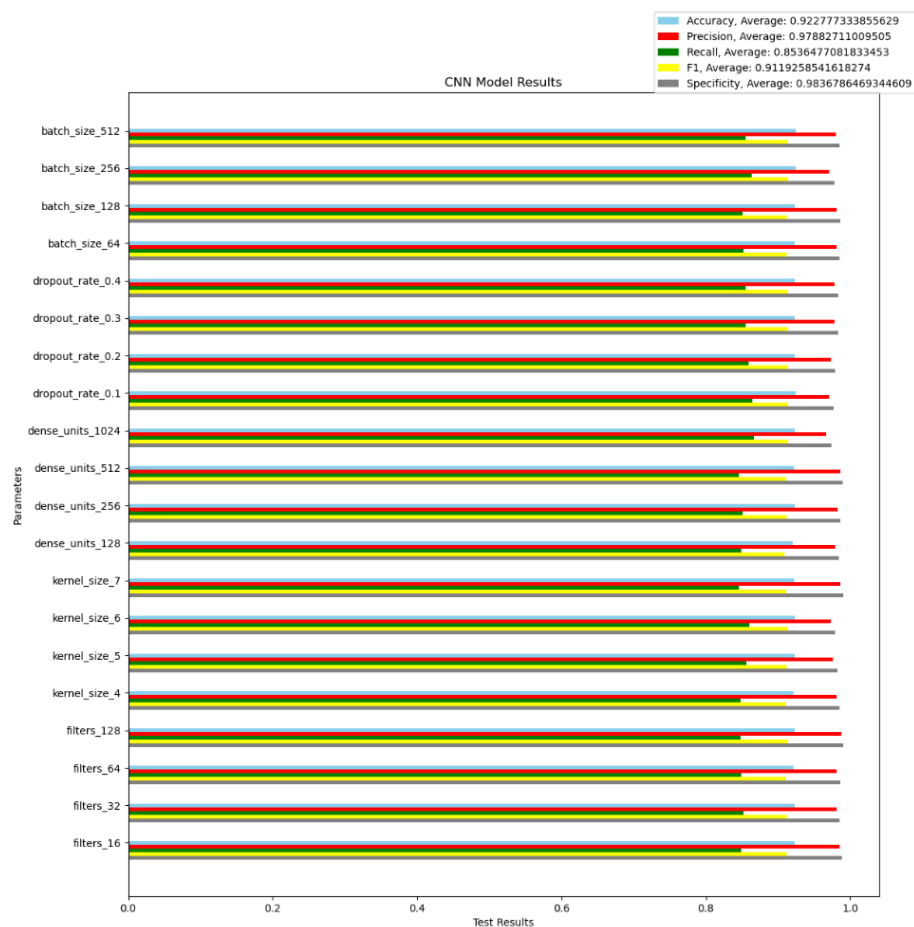
Η dropout κανονικοποίηση είναι ουσιώδης για την πρόληψη της υπερεκπαίδευσης. Ένας ρυθμός dropout 0.1 έχει καλή απόδοση σε όλες τις μετρικές, παρέχοντας έναν καλό συμβιβασμό μεταξύ πολυπλοκότητας του μοντέλου και κανονικοποίησης. Υψηλότεροι ρυθμοί dropout (π.χ., `dropout_rate_0.3` και `dropout_rate_0.4`) οδηγούν σε μείωση της απόδοσης, υποδεικνύοντας υπερβολική κανονικοποίηση.

5. Μέγεθος Δέσμης (Batch Size):

Η αλλαγή του batch size δεν φαίνεται να έχει σημαντική επίδραση στην απόδοση του μοντέλου σε αυτήν την περίπτωση. Οι παραλλαγές στις βαθμολογίες είναι σχετικά μικρές μεταξύ διαφορετικών batch size. Είναι σημαντικό να σημειωθεί ότι μικρότερα batch size (π.χ., `batch_size_64`) μπορεί να οδηγήσουν σε ταχύτερη σύγκλιση, αλλά η επίδραση είναι μικρή σε αυτό το σενάριο.


Συνολικά, η επιλογή των υπερπαραμέτρων πρέπει να καθοδηγείται από έναν συμβιβασμό μεταξύ της πολυπλοκότητας του μοντέλου και της αποφυγής της υπερπροσαρμογής. Είναι σημαντικό να πραγματοποιηθεί μια πιο εκτενής αναζήτηση υπερπαραμέτρων και ενδεχομένως να ληφθούν υπ' όψιν τεχνικές όπως το cross-

validation για την διασφάλιση μιας σταθερής κατανόησης της απόδοσης του μοντέλου σε διάφορες διαμορφώσεις. Επιπλέον, αυτές οι παρατηρήσεις είναι συγκεκριμένες στο δεδομένο dataset και task, και η γενίκευση σε άλλα datasets πρέπει να εξετασθεί εκτενέστερα. Επίσης θα πρέπει να εξεταστεί και η επέκταση του μοντέλου σε συνδυασμό με BiLSTM.




Εικόνα 7: Μετρικές Απόδοσης για Διαφορετικές Υπερπαραμέτρους


Ακολουθούν ενδεικτικά μερικοί πίνακες σύγχυσης για τα αποτελέσματα του μοντέλου για συγκεκριμένες παραμέτρους.




'filters': 32, 'kernel_size': 3, 'pool_size': 2, 'dense_units': 128, 'dropout_rate': 0.5, 'epochs': 20, 'batch_size': 32,



'filters': 64, 'kernel_size': 3, 'pool_size': 2, 'dense_units': 128, 'dropout_rate': 0.5, 'epochs': 20, 'batch_size': 32,



'filters': 16, 'kernel_size': 3, 'pool_size': 2, 'dense_units': 128, 'dropout_rate': 0.5, 'epochs': 20,



'filters': 128, 'kernel_size': 3, 'pool_size': 2, 'dense_units': 128, 'dropout_rate': 0.5, 'epochs': 20,

4

Συμπεράσματα - Επίλογος

4.1 Συμπεράσματα Εργασίας

Εν κατακλείδι είναι φανερό πως η χρήση Convolutional Neural Networks μπορεί να επιφέρει σημαντικά αποτελέσματα στην διάγνωση της αρρυθμίας με ΗΚΓ. Τα αποτελέσματα των πειραμάτων μας είναι ενθαρρυντικά για περαιτέρω έρευνα και μελλοντικές κατεύθυνσης με σκοπό την καλύτερη αντιμετώπιση καρδιακών παθήσεων και προβλημάτων. Η εκτεταμένη αξιολόγηση του συστήματος με διάφορες διαμορφώσεις υπερπαραμέτρων απέδωσε χρήσιμες γνώσεις αναφορικά με το πως κάθε παράμετρος αλληλεπιδρά με το σύστημα και το διαμορφώνει. Συνιστάται μία πιο εξαντλητική έρευνα των υπερπαραμέτρων σε συνδυασμό με περαιτέρω ανάπτυξη συστημάτων Τεχνητής Νοημοσύνης για βέλτιστα αποτελέσματα με γνώμονα πάντα την ασφάλεια και την χορήγηση της καλύτερης δυνατής διάγνωσης με αποτελεσματικότητα.

4.2 Μελλοντικές Κατευθύνσεις Έρευνας

Ο τομέας της αξιοποίησης της βαθιάς μάθησης για την αρρυθμία μέσω ΗΚΓ ανίχνευσης και ταξινόμησης παρουσιάζει συναρπαστικούς δρόμους για περαιτέρω εξερεύνηση. Μια πολλά υποσχόμενη κατεύθυνση περιλαμβάνει την ενσωμάτωση πολυμορφικών δεδομένων (multi-modal), συνδυάζοντας σήματα ΗΚΓ με άλλες ειδικές για τον ασθενή πληροφορίες[30], όπως το ιατρικό ιστορικό, οι παράγοντες του τρόπου ζωής και τα γενετικά δεδομένα του ασθενή. Αυτή η ολιστική προσέγγιση θα μπορούσε να ενισχύσει την ακρίβεια και να θέσει τα θεμέλια για την εξατομίκευση του χαρακτήρα των προβλέψεων αρρυθμίας.

Είναι σημαντικό όμως να σημειώσουμε ότι η ερμηνεία των μοντέλων βαθιάς μάθησης παραμένει ένας κρίσιμος τομέας προς βελτίωση και η μελλοντική έρευνα θα μπορούσε να επικεντρωθεί στην ανάπτυξη μοντέλων που παρέχουν διαφανείς πληροφορίες για τις διαδικασίες λήψης αποφάσεων[31], ενισχύοντας την εμπιστοσύνη μεταξύ των επαγγελματιών υγείας και των μοντέλων αυτών. Επιπλέον, η προσαρμογή των διενεργειών τέτοιων μοντέλων σε πραγματικό χρόνο με συστήματα παρακολούθησης[32] και υπολογιστών ακμής για συνεχή ανάλυση ΗΚΓ θα μπορούσε να συμβάλλει σε έγκαιρες παρεμβάσεις και βελτιωμένα αποτελέσματα για τους ασθενείς. Ιδιαίτερη προσοχή θα πρέπει να δοθεί στα προσωπικά δεδομένα των ασθενών[33], στην αποφυγή της προκατάληψης στα μοντέλα λόγω λαθών στα δεδομένα εκπαίδευσης[34] και στη συμμόρφωση, φορέων και δημιουργών τέτοιων μοντέλων, με τις συνεχόμενες αλλαγές στα νομοθετικά πλαίσια[35] γύρω από την χρήση Τεχνητής Νοημοσύνης στην υγεία.

Οι συνεργατικές προσπάθειες μεταξύ εμπειρογνομόνων μηχανικής μάθησης, καρδιολόγων, και επιστημόνων δεδομένων είναι απαραίτητες για την ανόρθωση του πλήρους δυναμικού της τεχνητής νοημοσύνης στον τομέα της καρδιακής υγείας και της υγείας γενικότερα.

5

Βιβλιογραφία

- [1] K. Bm, R. No, and : 20bec0503, “ADVANTAGES OF AI IN MEDICAL FIELD.”
- [2] A. Al Kuwaiti *et al.*, “A Review of the Role of Artificial Intelligence in Healthcare,” *Journal of Personalized Medicine*, vol. 13, no. 6. MDPI, Jun. 01, 2023. doi: 10.3390/jpm13060951.
- [3] K. Kędzierski, J. Radziejewska, A. Sławuta, M. Wawrzyńska, and J. Arkowski, “Telemedicine in Cardiology: Modern Technologies to Improve Cardiovascular Patients’ Outcomes—A Narrative Review,” *Medicina (Lithuania)*, vol. 58, no. 2. 2022. doi: 10.3390/medicina58020210.
- [4] G. D. Buckberg, N. C. Nanda, C. Nguyen, and M. J. Kocica, “What is the heart? Anatomy, function, pathophysiology, and misconceptions,” *Journal of Cardiovascular Development and Disease*, vol. 5, no. 2. 2018. doi: 10.3390/jcdd5020033.
- [5] M. A. Serhani, H. T. El Kassabi, H. Ismail, and A. N. Navaz, “ECG monitoring systems: Review, architecture, processes, and key challenges,” *Sensors (Switzerland)*, vol. 20, no. 6. 2020. doi: 10.3390/s20061796.
- [6] Q. Xiao *et al.*, “Deep Learning-Based ECG Arrhythmia Classification: A Systematic Review,” *Applied Sciences (Switzerland)*, vol. 13, no. 8. 2023. doi: 10.3390/app13084964.

- [7] Y. Ansari, O. Mourad, K. Qaraqe, and E. Serpedin, "Deep learning for ECG Arrhythmia detection and classification: an overview of progress for period 2017–2023," *Frontiers in Physiology*, vol. 14. 2023. doi: 10.3389/fphys.2023.1246746.
- [8] P. Rajpurkar, A. Y. Hannun, M. Haghpanahi, C. Bourn, and A. Y. Ng, "Cardiologist-Level Arrhythmia Detection with Convolutional Neural Networks."
- [9] R. Caruana, Y. Lou, J. Gehrke, P. Koch, M. Sturm, and N. Elhadad, "Intelligible Models for HealthCare," 2015. doi: 10.1145/2783258.2788613.
- [10] K. and N. R. O'Shea, "An Introduction to Convolutional Neural Networks," *Int J Res Appl Sci Eng Technol*, vol. 10, no. 12, 2015.
- [11] W. Lu, J. Li, J. Wang, and L. Qin, "A CNN-BiLSTM-AM method for stock price prediction," *Neural Computing and Applications*, vol. 33, no. 10. 2021. doi: 10.1007/s00521-020-05532-z.
- [12] M. Rhanoui, M. Mikram, S. Yousfi, and S. Barzali, "A CNN-BiLSTM Model for Document-Level Sentiment Analysis," *Mach Learn Knowl Extr*, vol. 1, no. 3, 2019, doi: 10.3390/make1030048.
- [13] Harmon, D. M., Sehwat, O., Maanja, M., Wight, J., & Noseworthy, P. A. (2023). Artificial Intelligence for the Detection and Treatment of Atrial Fibrillation. *Arrhythmia & electrophysiology review*, 12, e12. <https://doi.org/10.15420/aer.2022.31>
- [14] Fabio Quartieri, Manuel Marina-Breyse, Raquel Toribio-Fernandez, Carlos Lizcano, Annalisa Pollastrelli, Isabella Paini, Roberto Cruz, Andrea Grammatico, José María Lillo-Castellano, Artificial intelligence cloud platform improves arrhythmia detection from insertable cardiac monitors to 25 cardiac rhythm patterns through multi-label classification, *Journal of Electrocardiology*, Volume 81, 2023, Pages 4-12, ISSN 0022-0736, <https://doi.org/10.1016/j.jelectrocard.2023.07.001>.
- [15] Sun J. (2023). Automatic cardiac arrhythmias classification using CNN and attention-based RNN network. *Healthcare technology letters*, 10(3), 53–61. <https://doi.org/10.1049/htl2.12045>

- [16] Alowais, S.A., Alghamdi, S.S., Alsuhebany, N. *et al.* Revolutionizing healthcare: the role of artificial intelligence in clinical practice. *BMC Med Educ* **23**, 689 (2023). <https://doi.org/10.1186/s12909-023-04698-z>
- [17] Weeraratna, I. N., Kamble, A. R., & Luharia, A. (2023). Artificial Intelligence Applications for Biomedical Cancer Research: A Review. *Cureus*, *15*(11), e48307. <https://doi.org/10.7759/cureus.48307>
- [18] Das D et al. “An interpretable machine learning model for diagnosis of Alzheimer’s disease”. In: PeerJ (2019). url: <https://peerj.com/articles/6543/>.
- [19] Davenport, T., & Kalakota, R. (2019). The potential for artificial intelligence in healthcare. *Future healthcare journal*, *6*(2), 94–98. <https://doi.org/10.7861/futurehosp.6-2-94>
- [20] Ripa R, George T, Shumway KR, et al. Physiology, Cardiac Muscle. [Updated 2023 Jul 30]. In: StatPearls [Internet]. Treasure Island (FL): StatPearls Publishing; 2024 Jan-. Available from: <https://www.ncbi.nlm.nih.gov/books/NBK572070/>
- [21] Saxton A, Tariq MA, Bordoni B. Anatomy, Thorax, Cardiac Muscle. [Updated 2023 Aug 8]. In: StatPearls [Internet]. Treasure Island (FL): StatPearls Publishing; 2024 Jan-. Available from: <https://www.ncbi.nlm.nih.gov/books/NBK535355/>
- [22] Desai DS, Hajouli S. Arrhythmias. [Updated 2023 Jun 5]. In: StatPearls [Internet]. Treasure Island (FL): StatPearls Publishing; 2024 Jan-. Available from: <https://www.ncbi.nlm.nih.gov/books/NBK558923/>
- [23] Morgan, J. M., Kitt, S., Gill, J., McComb, J. M., Ng, G. A., Raftery, J., Roderick, P., Seed, A., Williams, S. G., Witte, K. K., Wright, D. J., Harris, S., & Cowie, M. R. (2017). Remote management of heart failure using implantable electronic devices. *European heart journal*, *38*(30), 2352–2360. <https://doi.org/10.1093/eurheartj/ehx227>
- [24] Gacek, A. (2012). An Introduction to ECG Signal Processing and Analysis. In: Gacek, A., Pedrycz, W. (eds) ECG Signal Processing, Classification and Interpretation. Springer, London. https://doi.org/10.1007/978-0-85729-868-3_2

- [25] Martínez-Sellés, M., & Marina-Breysse, M. (2023). Current and Future Use of Artificial Intelligence in Electrocardiography. *Journal of cardiovascular development and disease*, 10(4), 175. <https://doi.org/10.3390/jcdd10040175>
- [26] Loukas Ilias and Dimitris Askounis. “Explainable Identification of Dementia From Transcripts Using Transformer Networks”. In: IEEE Journal of Biomedical and Health Informatics 26.8 (2022), pp. 4153–4164. doi: 10.1109/JBHI.2022.3172479.
- [27] Sigrid Sterckx et al. ““You hoped we would sleep walk into accepting the collection of our data”: controversies surrounding the UK care.data scheme and their wider relevance for biomedical research”. In: (2015). url: <https://doi.org/10.1007/s11019-015-9661-6>.
- [28] Rajkomar A et al. “Ensuring Fairness in Machine Learning to Advance Health Equity”. In: (2018). url: <https://doi.org/10.7326/M18-1990>.
- [29] Accuracy of Heart Rate Measurement with Wrist-Worn Wearable Devices in Various Skin Tones: a Systematic Review. “Koerber D. and Khan S. and Shamsheri T. and Kirubarajan A. and Mehta S.” In: (2023). url: <https://doi.org/10.1007/s40615-022-01446-9>.
- [30] Hammad, M., Meshoul, S., Dziwiński, P., Pławiak, P., & Elgendy, I. A. (2022). Efficient Lightweight Multimodel Deep Fusion Based on ECG for Arrhythmia Classification. *Sensors (Basel, Switzerland)*, 22(23), 9347. <https://doi.org/10.3390/s22239347>
- [31] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. ”Why Should I Trust You?”: Explaining the Predictions of Any Classifier. 2016. arXiv: 1602.04938 [cs.LG].
- [32] Sarraju, A., & Turakhia, M. P. (2020). Wearables for arrhythmia care: Challenges and future prospects. *Cardiovascular digital health journal*, 1(2), 56–58. <https://doi.org/10.1016/j.cvdhj.2020.09.001>

- [33] Ezio Di Nucci. “Should we be afraid of medical AI?” In: *Journal of Medical Ethics* 45.8 (2019), pp. 556–558. issn: 0306-6800. url: <https://jme.bmj.com/content/45/8/556>.
- [34] Daneshjou R. et al. “Lack of Transparency and Potential Bias in Artificial Intelligence Data Sets and Algorithms A Scoping Review”. In: (2021). url: www.doi.org/10.1001/jamadermatol.2021.3129.
- [35] European Commission. “Proposal for a Regulation laying down harmonised rules on Artificial Intelligence (Artificial Intelligence Act)”. In: (2021). url: <https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=CELEX:52021PC0206>.
- [36] Niraj Varma, Frieder Braunschweig, Haran Burri, Gerhard Hindricks, Dominik Linz, Yoav Michowitz, Renato Pietro Ricci, Jens Cosedis Nielsen, Remote monitoring of cardiac implantable electronic devices and disease management, *EP Europace*, Volume 25, Issue 9, September 2023, euad233, <https://doi.org/10.1093/europace/euad233>